



SACC

2020 中国系统架构师大会

SYSTEM ARCHITECT CONFERENCE CHINA 2020

架构融合 云化共建

LIVE 2020年10月22日 - 24日网络直播

架构融合

云化共建

大规模微服务集群的智能运维实践

龚诚 58同城智能运维团队负责人

大规模微服务集群面临的挑战

- 智能运维概述
- 数据异常检测
- 告警质量治理
- 智能故障分析

<http://www.itpub.net/>

架构融合
云化共建

01

智能运维概述

大规模微服务集群面临的挑战

- 服务器规模越来越大
- 应用功能越来越丰富
- 服务的关联越来越复杂
- 引发故障的原因多种多样
- 涉及的团队和人员越来越多



智能运维，始于监控，扩至其他

- 监控全业务流程覆盖
 - 故障前给出服务质量和风险点评估，做出故障预警
 - 自动添加监控，添加默认告警策略，故障时自动发出告警
 - 多种方式的异常检测，自动维护异常判断阈值
 - 有效的告警收敛，多维度的告警合并，简单清晰的告警信息



根据故障发生时的告警信息，自动进行故障自愈

架构融合
云化共建

02

数据异常检测

一、自动采集数据


- 基础监控
 - 服务器存活监控，硬件监控，网络监控
 - 资源使用率监控：CPU、内存、磁盘空间、网卡流量等
- 通用服务监控
 - web服务：基于nginx日志实时分析，HTTP状态码、响应时间、可用性
 - 数据服务：基于基础框架或服务治理系统自动采集
 - 存储服务：基于统一方案，如：mysql、redis、mongodb等
 - 基础服务：k8s、nginx、DNS等
- 多种数据接入方式
 - 上传采集程序，作为agent插件执行
 - 业务程序通过调用函数上报数据
 - 通过HTTP协议上报数据

二、自动添加监控

基于CMDB信息自动添加：数据采集、告警策略、监控视图

添加告警的几个要素：

1. 集群名
2. 集群IP列表
3. 监控策略
4. 集群负责人



三、多类型的监控指标




- 静态阈值
 - 在固定范围内变化
 - 根据专家经验确定阈值
 - 如CPU、内存使用率
- 需调整的静态阈值
 - 无固定范围，随着业务发生变化
 - 根据指标的历史数据计算阈值
 - 如服务响应时间
- 无固定阈值
 - 无固定变化范围，有周期性
 - 随着用户访问的高低峰变化
 - 如PV、UV、订单量、收入等



(一) 静态阈值自动生成


基于样本统计分布自动计算动态阈值

- 3-sigma
 - 样本符合或近似正态分布
 - 易受异常值影响
- Tukey' s test
 - 不受少量异常值的影响
 - 有时过于敏感



(二) 周期性指标的异常检测

- 数据特点
 - 整体规律性较强
 - 每天作为一个周期
 - 短期小幅波动较多
- 适用场景
 - 网络的进出流量
 - 业务的访问量
 - 集群和域名的访问量
 - 宏观业务数据等



如何使用机器学习的方法

我们要解决什么样的问题

明确问题：



解决问题可能需要哪些数据



我们可以获取哪些数据

流量预测/异常检测

历史时刻对应的流量

处理数据：



数据清洗

特征工程

数据标记



清洗接口异常数据

统计判别结合无监督学习标记数据

训练模型：



选择模型

训练模型

验证模型



离线训练模型

交叉验证模型表现

使用模型：



线上加载


定期修正



BadCase分析

修正模型

流量预测及异常检测的技术框架



智能异常检测的效果



- 模型有较好的普适性
 - 适用于不同数量级的数据；
 - 适用于不同变化规律的数据；
 - 适用于不同业务的数据；

架构融合
云化共建

03

告警质量治理

告警质量治理

降低告警数量，提升告警信息质量

1. 告警收敛策略

- 减少告警的数量，减少对人的干扰

2. 智能告警合并

- 将同类的告警合并起来，并提供告警概况信息

3. 更直观的展示告警

- 通过微信告警展示更多维度的信息

一、告警收敛策略

1. 对告警的需求

- 告警收敛
- 精准告警

2. 告警发送策略

- 告警分级：邮件->微信->短信->语音
- 连续m次异常则告警/在m分钟时间段内有n次异常则告警
- 告警间隔5分钟，最多告警n次
- 30分钟后未处理则升级，1天后未处理则提醒
- 告警升级后使用升级后的告警级别和接收人

二、智能告警合并


- 合并收益
 - 避免海量告警轰炸
 - 快速掌握故障情况
 - 辅助决策故障根因
- 合并时间窗口
 - 兼顾合并效果和告警时效性
 - 合并时间窗口为1分钟
- 合并策略
 - 相同用户（对同一个人的告警合并）
 - 相同告警状态（异常，升级，恢复等）
 - 相同告警方式（语音，短信，微信等）
- 合并维度
 - 根据集群合并
 - 根据IP合并
 - 根据网段合并
 - 根据异常种类合并（宕机、端口不通等）
 - 根据宿主机与虚拟机的关系合并

智能告警合并——维度选择

基尼值

$$Gini(D) = 1 - \sum_{k=1}^{|Y|} p_k^2$$

类比决策树算法，基于基尼值最小化自动选择告警合并维度组合；



输入：数据集 $D = \{x_1(d_1, d_2, \dots, d_n), \dots, x_n(d_1, d_2, \dots, d_n)\}$

维度集 $A = (d_1, d_2, \dots, d_n)$

过程：MergeGenerate(D, A)

```
while  $A \neq \emptyset$  do
  min_gini = 0.5
  for  $d_i$  in  $A$  do
    for  $k = 1$  to  $|Y|$  do
       $P_k = \text{num}(D_{ik}) / \text{num}(D)$ 
      temp_gini =  $1 - \sum_{k=1}^{|Y|} p_k^2$ 
      if temp_gini < min_gini do
        min_gini = temp_gini
        split_dim =  $d_i$ 
    if min_gini == 0.5 do
      return
   $A = A \setminus \{d_i\}$ 
  for  $k = 1$  to  $|Y|$  do
    MergeGenerate( $D_{ik}, A$ )
```


智能告警合并——告警合并树

解决思路：

- 1.设计告警合并树算法
- 2.基于基尼值计算，得到纯度提升最高的树形划分

算法描述：

- 1.遍历全部备选维度，确认当前合并维度
- 2.基于合并维度划分数数据集，继续选择合并维度
- 3.到达停止条件后停止



智能告警

告警信息

58集团运维

监控告警通知
8月20日
(出现异常)集群monitor_all有22条监控指标ping_down的告警(连续1次异常)
系统状态: 出现异常
机器信息: monitor_all
监控指标: ping_down
异常描述: 集群monitor_all有22条监控指标ping_down的告警(连续1次异常)
异常判断:
告警时间: 2018-08-20 20:40:00
请及时处理该异常, 查看详情请点击链接。

详情

监控告警通知
8月20日
(恢复正常)集群monitor_all有21条监控指标ping_down的告警(连续3次异常)
系统状态: 恢复正常
机器信息: monitor_all
监控指标: ping_down
异常描述: 集群monitor_all有21条监控指标ping_down的告警(连续3次异常)
异常判断:
告警时间: 2018-08-20 20:41:00
请及时处理该异常, 查看详情请点击链接。

工单管理

监控系统

运维管理

合并的告警信息

我的异常

概况: 集群monitor_all有22条监控指标ping_down的告警(连续1次异常)

监控状态	PROBLEM
告警级别	短信(短信,微信,邮件)
告警时间	2018-08-20 20:40:00
告警发至	c...ping,d...g...li g...li...w...2 6,w...0,z...4...g s...

集群名	告警次数	监控指标	监控策略
monit or_all	PROB LEM 短信 [第1 次]	10...19 ping_down idc=...monitor_ip =10...3	连续1次异常 0!=100 宕机
monit or_all	PROB LEM 短信 [第1 次]	10...36 ping_down idc=...monitor_ip =10...3	连续1次异常 0!=100 宕机
monit or_all	PROB LEM 短信 [第1 次]	10...29 ping_down idc=...monitor_ip =10...3	连续1次异常 0!=100 宕机

合并的告警信息列表

查看告警详情

概况:(出现异常)(10.1...19)
(monitor_all)(宕机)

监控状态	PROBLEM(出现异常)
告警级别	短信(短信,微信,邮件)
服务器IP	10.1...19
集群名称	monitor_all
集群路径	58.1...op_monitor.monitor_all
监控指标	ping_down
数据标签	idc=...monitor_ip=10...3
异常描述	宕机
异常判断	连续1次异常:0(当前值)!=100(预设异常值)
告警次数	最大次数:3,当前次数:1
告警时间	2018-08-20 20:40:00
告警发至	d...u,z...4,g... i...g,z...w... 0,lit...c...g,v... b...
告警详情	

屏蔽告警时间段:

单条告警信息详情


智能告警合并——给出概况信息

告警状态	告警方式	告警合并概况	合并维度
异常告警	语音	集群 有22条宕机告警,当前集群服务器异常比例: 84.62%(22/26)	集群、指标
异常告警	微信	服务器 有5条JVM内存过高的告警	服务器、指标
重复提醒	短信	集群 有6条磁盘可用空间不足的告警,当前集群服务器异常比例: 21.43%(6/28)	集群、指标
告警升级	短信	机房有4条虚拟机宕机告警,由宿主机 宕机导致	宿主机、指标
异常告警	语音	机房有16条宕机的告警,疑似网络设备异常,异常服务器对应网段为 (网段IP异常比例: 100%(16/16))	网段、指标
异常告警	短信	服务器 在5个集群有5条JVM内存过高的告警	服务器、指标
异常告警	邮件	集群 的服务器 有3条JVM内存过高的告警	集群、服务器、指标

智能告警合并——减少告警数量

- 告警数量变化趋势

合并告警统计曲线



- 告警数量对比
 - 告警数量减少90%左右

三、更直观的告警信息展示

- 多种告警方式
 - 语音，短信，微信，邮件。包含必要的信息，简单清晰
- 推荐微信告警
 - 告警基本信息
 - 服务名称、实例IP、监控指标、数据标签、异常描述、持续时间
 - 告警条件、告警方式、告警接收人
 - 异常数据视图
 - 当前告警指标的数据视图
 - 告警根因分析图
 - 多服务间影响关系，多指标间影响关系，相关核心指标视图
 - 对告警的操作
 - 告警屏蔽、告警策略修改、告警订阅

架构融合
云化共建


04

智能故障分析

[illegible]

iwiki_..._web	web	che...guo1	结束	灰度升级	成功
callcenter...onebar_web	web	zha...i-web	结束	灰度升级	成功
iwiki_..._web	web	che...guo1	开始	灰度升级	成功
hbg_biz_...ebrokerbiz	BizForJob	ya...qin	结束	全量升级	成功
pay_s...ense	expense	guo...ang	结束	全量升级	成功
hbg_biz_...alebrokerbiz	BizForJob	ya...qin	开始	全量升级	成功
callcenter...nebar_web	web	zha...wei05	开始	灰度升级	成功
hbg_biz_...ebrokerbiz	hbgsalebrokerbiz	xux...yu	开始	全量升级	成功
carloan_...loanconfig	preloanconfig	ti...ilin	结束	全量升级	成功
hbg_repo_...s_node_vm	vm	su...33	结束	全量升级	成功
lbg_w...tentapi	contentapi	gon...gyou	结束	全量升级	成功
pay_s...xpense	expense	guo...ang	开始	全量升级	成功
iwiki_...web	web	che...guo1	结束	灰度升级	成功

从多系统中获取数据困难



转瞬即逝的故障现场




复杂的服务调用关系网





依赖人的经验和分析能力

多业务网络流量的相关性分析



	58_netflow	58_app_netflow	58_m_netflow	58_pc_netflow
58_netflow	1.000000	0.946268	-0.112809	0.011954
58_app_netflow	0.946268	1.000000	-0.224317	-0.135263
58_m_netflow	-0.112809	-0.224317	1.000000	0.254100
58_pc_netflow	0.011954	-0.135263	0.254100	1.000000

左图为58集团某业务流量总端；
右图为其对应的app、m、pc分端；
总端流量异常下跌时，基于流量曲线相关性
确定根因是app端流量下跌；






某业务流量与集群访问量的相关性分析



	tgw	app	log	community	recommend	web	my
tgw	1.000000	0.971606	0.976439	0.959763	0.968543	0.874415	-0.015356
app	0.971606	1.000000	0.979770	0.974313	0.979955	0.843315	-0.039738
log	0.976439	0.979770	1.000000	0.982673	0.985210	0.905142	-0.008561
community	0.959763	0.974313	0.982673	1.000000	0.978803	0.844919	0.015933
recommend	0.968543	0.979955	0.985210	0.978803	1.000000	0.861990	-0.023768
web	0.874415	0.843315	0.905142	0.844919	0.861990	1.000000	0.100565
my	-0.015356	-0.039738	-0.008561	0.015933	-0.023768	0.100565	1.000000

左图为58集团某业务流量；
右图为其对应的集群访问量；
同时段出现异常的集群访问量与业务
流量相关性明显高于正常集群；



智能故障排查和定位

1. 有领域知识和经验（构建知识图谱）
 - 服务的部署情况：服务调用链
 - 领域内专家经验：故障因果关系
2. 有逻辑分析能力（构建分析能力）
 - 赋予系统强大的逻辑分析能力
 - 通过调用链和故障因果关系自动定位故障原因
 - 将多系统的数据汇总、对齐，并自动进行分析
3. 直观展示分析结果（PC端，微信端）
 - 通过文字描述和根因分析图展示故障影响关系
 - 在一个页面中可以查看所有排查故障所需的数据

一、构建知识图谱


1. 服务调用链

- 基于公司内部基础架构和开发框架
- 采集开源软件等， SkyWalking、Zipkin、Pinpoint

2. 故障因果关系

- 引入运维专家经验
- 故障关联关系挖掘
- 存储在图数据库中

运维知识图谱——服务调用链



故障关联关系挖掘——多维数据的收集

数据是智能的基础

- 现实条件的限制注定了能拿到的数据是很有限的
- 不断收集，逐步打通，快速迭代

1. 监控配置
2. 历史告警事件
3. CMDB数据

1. 发布、变更操作
2. 数据库事件
3. 多平台告警

1. 故障关联
2. 服务部署、调用
3. 运维画像

基础数据

平台打通

关系挖掘

故障关联关系挖掘


频繁集挖掘算法

- 可获取频繁项集和关联规则；
- 优化性能，改进算法；

基于调用链获取原始数据集

- 此时数据集普遍较小，计算效率可接受；
- 减少随机因素干扰；

The Apriori Algorithm—An Example




故障关联关系挖掘——相关性检测


皮尔逊相关系数 $\rho(X, Y) = \frac{E[(X - \mu_x)(Y - \mu_y)]}{\sigma_x \sigma_y} = \frac{E[(X - \mu_x)(Y - \mu_y)]}{\sqrt{\sum_{i=1}^n (X_i - \mu_x)^2} \sqrt{\sum_{i=1}^n (Y_i - \mu_y)^2}}$

对于关联告警项，有告警时刻对应值为1，无告警时刻对应值为0，形成一条时间序列，利用皮尔逊系数过滤干扰告警项；

	B	C
A	1.000000	0.353553

此时我们认为B更可能是A告警的根因





http://www.itpub.net/

二、构建分析能力


常见的根因分析场景

- 多服务调用
 - 可用性和响应时间逐级影响
- 单服务异常
 - 可用性异常，响应时间异常，访问量异常，容量不足等
- 单机异常：
 - 物理机或虚拟机宕机，服务器假死，系统资源不足，端口不通，进程异常等
- 机房网络流量异常：
 - 流量突增或突降，流量增长或减少等

异常事件的因果关系


1. 多服务调用分析

- 调用链上多个服务出现异常



2. 指标关联分析

- 关联的异常同时发生



3. 操作关联分析

- 变更操作引起异常



使用行为树控制分析逻辑


将宏观分析逻辑用行为树表示出来

1. 逻辑节点


- 选择节点：顺序执行，遇到成功则结束
- 顺序节点：顺序执行，失败则退出，直到结束
- 重复节点：重复执行，直到满足退出条件

2. 行为节点






- 数据处理分析



根因分析框架



三、根因分析视图



故障辅助排查视图

根因分析概述

- 概述文字描述
- 异常因果关系图
- 服务调用链及状态

服务变更纪录

- 云平台, 堡垒机等

异常指标数据

- 根因关联指标数据
- 相似变化趋势指标

快照及日志


- 系统快照 (进程的CPU、内存)
- Nginx日志概况及详情

相关核心指标数据

- 访问量、可用性、响应时间

基础监控指标数据

- CPU、内存、网卡、磁盘IO



传统运维与智能运维的对比

• 传统运维

- 监控指标侧重单机运行状态
- 做固定阈值的异常判断
- 告警数量较大，误报较多，信息量小
- 做故障现象的告警，需要大量的人工分析
- 发现问题而不处理，由人决定如何处理
- 发出告警时已经出现故障

• 智能运维

- 监控指标侧重业务整体运行情况
- 支持多种类型监控指标的异常检测
- 告警精准，体现故障的严重程度和影响范围
- 有强大的分析能力，揭示故障的根源原因
- 根据故障根源原因智能决策，进行故障自愈
- 故障前给出风险提示和优化建议

Thanks

<http://www.itpub.net/>

